

Classificação de Áreas Queimadas em Imagens Landsat Utilizando SVM (Linear Support Vector Machine)

Trabalho Final — Reconhecimento de Padrões

Resumo

Este trabalho apresenta uma metodologia de reconhecimento de padrões para detecção de áreas queimadas utilizando imagens Landsat e índices de vegetação NDVI obtidos em períodos pré e pós-fogo. O método emprega um classificador SVM linear treinado a partir de amostras balanceadas de pixels queimados e não queimados provenientes de múltiplas cenas. Foram utilizadas variáveis derivadas do NDVI, incluindo diferença temporal, razão espectral e variação absoluta, visando aumentar a capacidade discriminativa do modelo. O treinamento foi realizado com duas cenas Landsat e posteriormente aplicado em uma terceira cena independente para validação. O modelo apresentou boa capacidade de generalização espacial, sendo avaliado por métricas como acurácia, precisão, recall, F1-score, IoU e matriz de confusão. Além disso, foi gerado um mapa temático classificado das áreas queimadas detectadas.

Entradas e Saídas

Entradas

O sistema utiliza como dados de entrada:

- Imagens raster Landsat contendo:
 - NDVI pré-queimada (`ndvi_pre`)
 - NDVI pós-queimada (`ndvi_pos`)
- Máscaras binárias de treinamento:
 - `0` = área não queimada
 - `1` = área queimada
- Conjunto de cenas Landsat para treinamento e teste.

Saídas

O processamento gera:

- Modelo SVM treinado;
- Predição das classes queimado/não queimado;
- Métricas quantitativas de desempenho:
 - Accuracy
 - Precision
 - Recall
 - F1-score
- Matriz de confusão;
- Mapa classificado final em formato GeoTIFF;

Metodologia

Pré-processamento e organização dos dados

O experimento foi desenvolvido a partir de imagens Landsat previamente processadas para geração do índice de vegetação NDVI (Normalized Difference Vegetation Index) em períodos pré e pós-queimada. Para cada cena analisada foram utilizados:

- NDVI anterior ao evento de fogo;
- NDVI posterior ao evento;
- máscara binária de referência contendo pixels classificados como queimados (1) e não queimados (0).

Inicialmente, os rasters foram carregados utilizando a biblioteca Rasterio, sendo realizada a leitura apenas da banda principal de cada arquivo GeoTIFF.

Como diferentes cenas podem apresentar pequenas discrepâncias dimensionais decorrentes do processamento orbital, os rasters foram ajustados para dimensões compatíveis por meio do recorte para o menor tamanho comum entre as imagens pré e pós-evento. Essa etapa garantiu alinhamento espacial entre os dados utilizados na extração das variáveis espectrais.

Posteriormente, foi realizado um procedimento de limpeza numérica visando eliminar inconsistências frequentemente presentes em produtos derivados de sensoriamento remoto, tais como: valores nulos (NaN); valores infinitos; pixels inválidos; etc.

Além disso, regiões associadas a corpos d'água foram removidas do conjunto de treinamento por meio da aplicação de uma máscara baseada em valores negativos de NDVI. Essa etapa mostrou-se importante para reduzir falsos positivos, uma vez que superfícies aquáticas podem apresentar comportamento espectral semelhante ao de áreas queimadas em determinadas situações.

Por fim, os atributos foram limitados ao intervalo espectral $[-1,1]$, reduzindo efeitos de valores extremos e garantindo estabilidade numérica durante o treinamento do classificador.

Balanceamento e amostragem dos dados

Problemas de detecção de áreas queimadas normalmente apresentam forte desbalanceamento entre classes, uma vez que a quantidade de pixels não queimados tende a ser significativamente superior à quantidade de pixels queimados.

Esse cenário pode induzir o modelo supervisionado a favorecer excessivamente a classe majoritária, comprometendo a capacidade de detecção das áreas queimadas.

Para minimizar esse problema, foi adotada uma estratégia de amostragem balanceada por classe. Inicialmente, os pixels pertencentes às classes queimado (1) e não queimado (0) foram separados individualmente. Em seguida, foi realizada uma seleção aleatória estratificada contendo a mesma quantidade de amostras para ambas as classes.

O número máximo de amostras por classe foi definido em 25.000 pixels, totalizando aproximadamente 50.000 amostras utilizadas no treinamento.

Essa estratégia apresentou três vantagens principais: redução do viés do modelo para a classe dominante; maior estabilidade estatística do treinamento e redução do custo computacional associado ao treinamento do SVM.

Além disso, o balanceamento contribuiu significativamente para melhorar métricas associadas à classe minoritária, especialmente Recall e F1-score.

Treinamento e validação do classificador SVM

O modelo supervisionado utilizado foi o Support Vector Machine (SVM), implementado por meio da classe LinearSVC da biblioteca scikit-learn.

Antes do treinamento, os atributos espectrais foram normalizados utilizando o método StandardScaler, responsável por padronizar os dados para média zero e variância unitária. Essa etapa é fundamental em modelos SVM, uma vez que o algoritmo é sensível à escala dos atributos.

O treinamento foi realizado utilizando duas cenas Landsat independentes, enquanto uma terceira cena foi reservada exclusivamente para validação do modelo. Essa estratégia permitiu avaliar a capacidade de generalização espacial do classificador em áreas não utilizadas durante o treinamento.

O modelo foi configurado com:

- penalização linear (`LinearSVC`);
- ponderação balanceada entre classes (`class_weight='balanced'`);
- limite elevado de iterações para convergência numérica.

A função objetivo do SVM consiste em encontrar um hiperplano ótimo capaz de maximizar a separação entre as classes queimado e não queimado no espaço multidimensional de atributos espectrais.


Após o treinamento, o modelo foi aplicado pixel a pixel sobre a cena de teste para geração das predições temáticas.

Resultados Obtidos

O modelo apresentou acurácia global de 80,14%; entretanto, devido ao forte desbalanceamento entre as classes, essa métrica isoladamente não representa adequadamente o desempenho do classificador. O elevado recall da classe queimada (83,43%) indica alta capacidade de detecção das áreas queimadas, reduzindo a ocorrência de falsos negativos. Em contrapartida, a baixa precision (14,04%) evidencia elevada incidência de falsos positivos, refletida também nos valores de IoU (13,66%) e F1-score (24,04%). A matriz de confusão demonstra que o modelo assumiu um comportamento mais sensível à detecção de queimadas, priorizando a identificação da classe minoritária mesmo ao custo de superestimativas espaciais.

Classification Report:

	precision	recall	f1-score	support
0.0	0.99	0.80	0.89	48117
1.0	0.14	0.83	0.24	1883
accuracy			0.80	50000
macro avg	0.57	0.82	0.56	50000
weighted avg	0.96	0.80	0.86	50000



Conclusão

Os resultados demonstraram que o modelo SVM foi capaz de generalizar a detecção de áreas queimadas entre diferentes cenas Landsat, apresentando elevada sensibilidade para identificação da classe de interesse. Apesar da boa capacidade de detecção, observou-se significativa ocorrência de falsos positivos, principalmente em regiões com comportamento espectral semelhante às áreas queimadas. Ainda assim, a metodologia mostrou potencial para aplicações em monitoramento ambiental, podendo ser aprimorada com a incorporação de novos atributos espectrais e técnicas de pós-processamento espacial.