

# Classificação de Áreas Queimadas com Multilayer Perceptron (MLP)

Trabalho Final — Reconhecimento de Padrões

Sensoriamento Remoto Orbital · Landsat 8/9 · Treino: 220\_075 + 221\_074 · Teste: 222\_074 ·  
Agosto de 2024


## Resumo

Rede neural MLP em PyTorch com **10 features espectrais** (B4, B5, B7, NDVI e NBR — pré e pós-queimada) foi treinada nas cenas Landsat 8/9 220\_075 e 221\_074 e avaliada de forma cega na cena 222\_074 (40,3 milhões de pixels, 2,96% queimada). Hiperparâmetros otimizados por Optuna (5 *trials*) resultaram em arquitetura de 2 camadas  $\times$  64 neurônios com Adam e Dropout = 0,256. A validação cruzada estratificada 5-fold (cenas treino) atingiu **F1** =  $0,722 \pm 0,002$  e **AUC** =  $0,812 \pm 0,002$ ; no teste cego, **AUC** = 0,830 e Recall = 0,713, indicando boa capacidade discriminativa com precisão limitada pelo forte desequilíbrio de classes (97:3) na cena de teste.

## 1. Problema, Entradas e Saída do Modelo

**Objetivo:** classificar cada pixel de uma imagem de satélite Landsat 8/9 (resolução 30 m) em uma de duas classes: **Classe 0 — Não queimada** | **Classe 1 — Queimada**.

A Figura 1 resume o fluxo completo do modelo.



**Figura 1:** Fluxo entrada–modelo–saída da MLP para classificação de queimadas.

## 2. Metodologia

### 2.1. Dados, protocolo e desbalanceamento


**Cenas:** três cenas Landsat 8/9 (Coleção 2, reflectância de superfície, agosto de 2024): 220\_075 (LC09, 29/08), 221\_074 (LC08, 28/08) e 222\_074 (LC09, 27/08).

**Protocolo treino/val/teste:**

- **Treino + Validação:** cenas 220\_075 e 221\_074 — 100k pixels por classe de cada cena = 400k pixels totais (balanceados 50/50).
- **Validação:** Stratified 5-Fold CV no conjunto de treino, preservando proporção de classes em cada fold.

- **Teste cego:** todos os 40,3M pixels válidos da cena 222\_074 (2,96% queimada), nunca vistos durante treino.

A Figura 2 ilustra o forte desbalanceamento de classes nas cenas originais — razão de até 18:1 —, justificando a amostragem balanceada e o uso de `class_weight` na função de perda.



**Figura 2:** Desbalanceamento de classes: razão 18:1 no dataset completo (esq.), distribuição por cena (centro) e amostragem balanceada 100k/classe (dir.).

## 2.2. Arquitetura e treinamento

|                        |                                                                       |
|------------------------|-----------------------------------------------------------------------|
| <b>Entrada</b>         | 10 neurônios (B4, B5, B7, NDVI, NBR $\times$ pré+pós)                 |
| <b>Camadas ocultas</b> | $2 \times 64$ neurônios — BatchNorm1d + ReLU + Dropout(0,256)         |
| <b>Saída</b>           | 2 logits $\rightarrow$ CrossEntropyLoss com pesos de classe           |
| <b>Anti-leakage</b>    | StandardScaler fitado <i>somente</i> nos dados de treino de cada fold |
| <b>Regularização</b>   | Early Stopping (paciência 10); Dropout estocástico                    |


Optuna TPE Sampler (5 *trials*, MedianPruner) minimizou a *val\_loss*. Parâmetros fixos: Adam ( $\alpha = 10^{-3}$ ), batch 1024, *n\_epochs*  $\leq 50$ .

## 3. Resultados

### 3.1. Validação cruzada — métricas por fold


**Tabela 1:** Stratified 5-Fold CV — cenas 220\_075 + 221\_074 (400k pixels). Métricas referem-se à classe queimada (positiva).

| Fold         | Accuracy      | Precision     | Recall        | F1            | AUC-ROC       |
|--------------|---------------|---------------|---------------|---------------|---------------|
| 1            | 0,7309        | 0,7454        | 0,7013        | 0,7227        | 0,8099        |
| 2            | 0,7317        | 0,7564        | 0,6835        | 0,7181        | 0,8114        |
| 3            | 0,7321        | 0,7472        | 0,7017        | 0,7237        | 0,8108        |
| 4            | 0,7345        | 0,7586        | 0,6880        | 0,7216        | 0,8143        |
| 5            | 0,7342        | 0,7563        | 0,6912        | 0,7223        | 0,8135        |
| <b>Média</b> | <b>0,7327</b> | <b>0,7528</b> | <b>0,6931</b> | <b>0,7217</b> | <b>0,8120</b> |
| DP           | 0,0015        | 0,0055        | 0,0079        | 0,0022        | 0,0019        |



**Figura 3:** Accuracy, Precision e F1 por fold (esq.) e curva de loss média (dir.).

### 3.2. Teste cego — cena 222\_074



(a) CM — TN= 32,6M, FP= 6,5M, FN= 343k, TP= 851k.

(b) Curva ROC — AUC= 0,830.

**Figura 4:** Desempenho no teste cego 222\_074 (40,3M pixels, 2,96% queimada).

| Conjunto / Modelo          | Acc.  | Prec. | Recall | F1     | AUC   |
|----------------------------|-------|-------|--------|--------|-------|
| MLP — Val. cruzada (média) | 0,733 | 0,753 | 0,693  | 0,722  | 0,812 |
| MLP — Teste 222_074 (40M)  | 0,830 | 0,116 | 0,713  | 0,199* | 0,830 |

\*Precision baixa. AUC indica separabilidade real.

## 4. Conclusão

A MLP (2 camadas  $\times$  64 neurônios, Adam, Dropout = 0,256, 10 features) atingiu F1 = 0,722 e AUC = 0,812 na validação cruzada, sem *overfitting*. No teste cego 222\_074, AUC = 0,830 confirma separabilidade espectral, mas a Precision cai para 0,116 com limiar 0,5 — consequência do treino balanceado (50/50) aplicado a uma cena com 2,96% de queimada.

## Referências

- [1] E. Chuvieco *et al.*, “Generation and analysis of a new global burned area product based on MODIS 250 m reflectance bands,” *Earth System Science Data*, vol. 11, pp. 529–551, 2019.
- [2] C. H. Key e N. C. Benson, “Landscape Assessment: Composite Burn Index,” in *FIREMON*, USDA Forest Service, RMRS-GTR-164-CD, 2006.
- [3] Y. LeCun, Y. Bengio e G. Hinton, “Deep learning,” *Nature*, vol. 521, pp. 436–444, 2015.
- [4] J. Bergstra *et al.*, “Algorithms for hyper-parameter optimization,” *NeurIPS*, vol. 24, pp. 2546–2554, 2011.