

Classificação Não Supervisionada de Áreas Queimadas com *Self-Organizing Map* (SOM) e Imagens Landsat 8

Trabalho Final — Reconhecimento de Padrões

Sensoriamento Remoto Orbital · Landsat 8/9 · Cena 221_074 · Agosto de 2024

Resumo

Uma *Self-Organizing Map* (SOM) foi aplicada a uma cena Landsat 8 pós-queimada para classificar cada pixel em três classes espectrais — **Queimada**, **Não Queimada** e **Água** — sem utilizar nenhum rótulo. O modelo identificou aproximadamente **154 mil hectares de área queimada** (4,3% da cena).

1. Problema, Entradas e Saída do Modelo

Objetivo: identificar automaticamente áreas queimadas em imagens de satélite, classificando cada pixel em **Queimada**, **Não Queimada** ou **Água** — **sem nenhuma amostra rotulada**.

A Figura 1 resume o fluxo completo do modelo.




Figura 1: Fluxo entrada–modelo–saída da SOM para classificação de queimadas.

2. Metodologia

2.1. Dados

A cena utilizada é uma imagem Landsat 8 (resolução 30 m, agosto de 2024) do Cerrado brasileiro, com par pré e pós-queimada para calcular as variações espectrais. Os atributos são normalizados antes do treinamento.

Os dois índices de variação são os mais informativos: Δ NBR (queda no índice de queima) e Δ NDVI (queda na cobertura vegetal) juntos identificam cicatrizes de fogo com alta especificidade.




Figura 2: Atributos de entrada da cena pós-queimada. Os índices de variação ΔNBR e ΔNDVI (última linha) revelam com nitidez as cicatrizes de queimada.

2.2. Como a SOM funciona

1. **Treinamento:** a SOM organiza neurônios em uma grade 2D de forma que pixels espectralmente similares ativem neurônios próximos entre si.
2. **Agrupamento:** os pesos dos neurônios são agrupados em 3 clusters por K-Means, formando as três classes.
3. **Atribuição:** cada cluster recebe um rótulo semântico por heurística espectral — sem rótulos humanos: ΔNBR alto $\rightarrow$ Queimada; NIR baixo + NDVI negativo $\rightarrow$ Água; demais $\rightarrow$ Não Queimada.
4. **Inferência:** cada pixel da cena completa é classificado pela classe do neurônio mais próximo (BMU).

Os hiperparâmetros da grade (tamanho, taxa de aprendizado e raio de vizinhança) foram otimizados automaticamente por **Optuna** (20 tentativas, TPE Sampler).

3. Resultados

3.1. Otimização e organização topológica





Figura 3: Busca de hiperparâmetros pelo Optuna: cada ponto é uma configuração testada. A melhor configuração encontrada usa grade 15×15 neurônios, garantindo boa separação espectral sem sobrecarga computacional.



(a) Grade SOM treinada com os 3 clusters K-Means sobrepostos à U-Matrix. Regiões escuras marcam fronteiras espectrais entre classes. (b) Separação dos clusters no espaço espectral (esq.) e área estimada por classe em hectares (dir.).

Figura 4: Organização topológica da SOM e distribuição das classes.

3.2. Qualidade do modelo

Métrica	Valor	Interpretação
Quantization Error (QE)	0,572	Bom — neurônios representam bem os pixels
Topographic Error (TE)	0,133	Bom — vizinhança espacial preservada
Silhouette	0,341	Aceitável — classes com alguma sobreposição

A sobreposição espectral entre solo exposto não queimado e cicatrizes recentes é a principal fonte de incerteza — limitação compartilhada com métodos supervisionados.

3.3. Saída espacial




Figura 5: Esquerda: composição falsa-cor B7/B5/B4 da cena pós-queimada (áreas queimadas em vermelho-vivo). Direita: mapa de classificação SOM — as cicatrizes de queimada são identificadas sem nenhum rótulo.

4. Conclusão

A SOM detectou **cerca de 154 mil hectares de área queimada** na cena. O modelo confirmou que a variação do NBR pós-queimada é o atributo mais discriminativo, com valor médio no cluster queimado acima do limiar estabelecido na literatura para queimadas moderadas [3].

Principal vantagem: dispensa completamente amostras rotuladas, podendo ser aplicado a qualquer cena Landsat sem trabalho de campo. **Principal limitação:** a heurística de atribuição de classes pode falhar em regiões com solo exposto por seca severa, onde a assinatura espectral se confunde com cicatrizes de fogo.

Referências

- [1] T. Kohonen, “Self-organized formation of topologically correct feature maps,” *Biological Cybernetics*, vol. 43, pp. 59–69, 1982.
- [2] E. Chuvieco *et al.*, “Generation and analysis of a new global burned area product based on MODIS 250 m reflectance bands,” *Earth System Science Data*, vol. 11, pp. 529–551, 2019.
- [3] C. H. Key e N. C. Benson, “Landscape Assessment: Composite Burn Index,” in *FIREMON*, USDA Forest Service, RMRS-GTR-164-CD, 2006.
- [4] J. Vesanto e E. Alhoniemi, “Clustering of the self-organizing map,” *IEEE Trans. Neural Networks*, vol. 11, pp. 586–600, 2000.