

Classificação Supervisionada de Áreas Queimadas com SVM Kernel RBF e Imagens Landsat 8/9

Trabalho Final — Reconhecimento de Padrões

Sensoriamento Remoto Orbital · Landsat 8/9 · Cenas 220_075, 221_074 e 222_074 · Agosto de 2024

Resumo

Uma Máquina de Vetores de Suporte (SVM) com kernel RBF foi treinada com amostras rotuladas de uma cena Landsat para classificar cada pixel em **Queimado** ou **Não Queimado**. Usando 10 atributos espectrais extraídos de imagens pré e pós-queimada, o modelo generalizou com alto desempenho para duas cenas geograficamente independentes — demonstrando que a assinatura espectral de queimadas é robusta o suficiente para ser aprendida por um único conjunto de treinamento.

1. Problema, Entradas e Saída do Modelo

Objetivo: dado um pixel de uma imagem de satélite, determinar se ele pertence a uma área que sofreu queimada recente ou não — **classificação binária supervisionada pixel a pixel**.

A Figura 1 resume o fluxo completo do modelo.




Figura 1: Fluxo entrada–modelo–saída da SVM RBF para classificação de queimadas.

2. Metodologia

2.1. Dados e estratégia de treino/teste

Foram usadas três cenas Landsat 8/9 localizadas no estado de São Paulo (agosto de 2024), cada uma com um par de imagens pré e pós-queimada:

- **220_075** — cena de **treino e validação**, com máscara de referência (*ground-truth*) disponível.
- **221_074** e **222_074** — cenas de **teste cego**, geograficamente distintas, nunca vistas pelo modelo durante o treino.

Adicionalmente, imagens com cobertura de nuvens foram incluídas no treino como amostras da classe *não queimada*, aumentando a robustez do modelo a condições de nebulosidade.

2.2. Atributos espectrais

Para cada pixel, cinco atributos são extraídos da imagem pré-queimada e outros cinco da imagem pós-queimada, formando um vetor de **10 features**:

Atributo	O que mede	Por que importa
B4 (Red)	Reflectância no vermelho	Aumenta após queimada
B5 (NIR)	Reflectância no infravermelho próximo	Cai após destruição da vegetação
B7 (SWIR2)	Reflectância no infravermelho de onda curta	Alto em solo exposto e queimado
NDVI	Índice de vegetação	Queda indica perda de cobertura vegetal
NBR	Índice de queimada	Principal discriminador de cicatrizes

2.3. Como a SVM RBF funciona

1. **Treinamento:** a SVM aprende uma fronteira de decisão não-linear no espaço dos 10 atributos, separando pixels queimados dos não queimados. Apenas as amostras mais próximas da fronteira — os *vetores de suporte* — definem o modelo final.
2. **Otimização:** os hiperparâmetros de regularização (C) e forma do kernel (γ) foram ajustados automaticamente via **Optuna** (50 tentativas, TPE Sampler), maximizando o F1 em validação cruzada.
3. **Inferência:** o modelo classifica a cena de teste inteira em lotes, produzindo a classe binária e a probabilidade de cada pixel.

3. Dados de Entrada

A Figura 2 mostra a cena de treino antes e após a queimada. Na composição falsa-cor B7/B5/B4, as áreas queimadas aparecem em vermelho intenso — reflexo da alta reflectância em SWIR2 e colapso do NIR. Esta separabilidade visual é o que a SVM aprende a capturar numericamente.




Figura 2: Cena de treino 220_075: composição falsa-cor pré-queimada (esq.), pós-queimada (centro) e máscara *ground-truth* (dir.). As áreas queimadas aparecem em vermelho na imagem pós-queimada.

4. Resultados

4.1. Otimização de hiperparâmetros

A busca automática pelo Optuna encontrou rapidamente a região de melhor desempenho no espaço de configurações. A Figura 3 mostra a convergência do F1 ao longo das 50

tentativas e a distribuição das configurações testadas — a maioria dos melhores resultados concentra-se em valores altos de regularização.




Figura 3: Busca de hiperparâmetros pelo Optuna (50 tentativas): evolução do melhor F1 acumulado (esq.) e distribuição dos pontos testados no espaço $C \times \gamma$ (dir.), coloridos pelo F1 obtido.


4.2. Desempenho nas cenas de teste

O modelo foi avaliado em duas cenas completamente independentes. A Tabela 1 resume os resultados — todos os conjuntos, incluindo os testes cegos, atingiram F1 acima de 0,98 e AUC-ROC perfeita, indicando boa generalização espacial.

Tabela 1: Desempenho da SVM RBF. F1 e Precisão referem-se à classe queimada. AUC-ROC = 1,000 em todos os conjuntos.

Conjunto	Acurácia	Precisão	Recall	F1
Treino (50 mil amostras)	99,96%	98,69%	100,0%	99,34%
Validação (12 mi pixels)	99,85%	98,40%	99,76%	99,07%
Teste cego 221_074 (40 mi)	99,91%	98,60%	99,64%	99,12%
Teste cego 222_074 (40 mi)	99,88%	96,83%	99,30%	98,05%

4.3. Matrizes de confusão e curvas ROC



(a) Teste cego 221_074 — F1 = 99,1%.

(b) Teste cego 222_074 — F1 = 98,1%.

Figura 4: Matrizes de confusão e curvas ROC dos testes cegos. A curva ROC perfeita confirma separabilidade completa entre as classes no espaço de probabilidade.

4.4. Saída espacial — predição vs. realidade




Figura 5: Cena 221_074: (a) falsa-cor pós-queimada; (b) *ground-truth*; (c) predição binária; (d) mapa de probabilidade — regiões centrais das cicatrizes apresentam alta confiança (próximo a 1,0), com incerteza maior apenas nas bordas.




Figura 6: Cena 222_074: o modelo mantém boa correspondência com o *ground-truth*, com ligeiro aumento de falsos positivos em regiões de solo exposto — esperado na cena com menor proporção de área queimada.

5. Conclusão

A SVM RBF aprendeu a identificar áreas queimadas a partir de amostras de uma única cena e generalizou corretamente para regiões geograficamente distintas, atingindo F1 acima de 98% nos dois testes cegos com AUC-ROC perfeita. O modelo utilizou apenas **105 vetores de suporte** — número muito baixo para o espaço de 50 mil amostras de treino — confirmando que as classes são espectralmente bem separadas.

A principal limitação é a confusão entre solo exposto e cicatrizes recentes, problema partilhado com métodos não supervisionados e que persiste mesmo com 10 atributos espectrais.

Referências

- [1] C. Cortes e V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, pp. 273–297, 1995.
- [2] C. H. Key e N. C. Benson, “Landscape Assessment: Composite Burn Index,” in *FIREMON*, USDA Forest Service, RMRS-GTR-164-CD, 2006.

- [3] J. Bergstra *et al.*, “Algorithms for hyper-parameter optimization,” in *NeurIPS*, vol. 24, pp. 2546–2554, 2011.