

Reconhecimento de Padrões

Agrupamento via BSAS, Janelas de Parzen e KNN

Aluno – Disciplina de Reconhecimento de Padrões

27 de abril de 2026

Resumo

Este trabalho implementa e avalia três propostas de agrupamento sobre os conjuntos de dados *Iris* e *Wine*. A primeira proposta combina o método BSAS, usado para **estimar** o número de agrupamentos por análise da derivada discreta da curva $c(\tau)$, com o agrupamento hierárquico de Ward, responsável pelo **particionamento** efetivo. A segunda e a terceira propostas utilizam, respectivamente, **Janelas de Parzen** (com uma estratégia *mode-seeking* via *mean-shift* sobre a densidade estimada) e **KNN** (com grafo de vizinhança mútua e filtragem por densidade). Todos os experimentos foram conduzidos no espaço padronizado (z -score) e a avaliação foi feita de forma qualitativa por meio de visualizações PCA-2D, matrizes de confusão e índices ARI/NMI.

1 Introdução e formulação

O problema de agrupamento consiste em particionar um conjunto $\mathcal{D} = \{x_i \in \mathbb{R}^n : i = 1, \dots, m\}$ em K subconjuntos disjuntos sem rótulos disponíveis durante o ajuste. Tipicamente, K é desconhecido: identificá-lo a partir dos próprios dados é parte central da tarefa. Métodos baseados em distância (BSAS, K -médias, hierárquicos) supõem agrupamentos compactos em torno de centros; métodos baseados em densidade (Parzen, KNN, DBSCAN) particionam pelo suporte da função de densidade subjacente. Ambas as famílias são exploradas neste trabalho.

Datasets. Trabalhamos com dois conjuntos clássicos do UCI/`sklearn`. *Iris* possui $m = 150$ observações em $\mathbb{R}^4$ distribuídas em três classes. *Wine* possui $m = 178$ observações em $\mathbb{R}^{13}$ também em três classes. Em *Wine*, atributos como *proline* aparecem em ordens de centenas a milhares, enquanto outros (e.g. *ash*) ficam próximos a 2. Como todos os métodos aqui usados se apoiam em distâncias euclidianas, atributos de maior escala dominariam o cálculo. Por isso, padronizamos cada atributo via z -score:

$$\tilde{x}_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}, \quad j = 1, \dots, n. \quad (1)$$

A projeção bidimensional via PCA é usada *apenas* para visualização; o agrupamento ocorre no espaço padronizado original. A Figura 1 apresenta os dados padronizados projetados em duas componentes principais.




Figura 1: Projeção PCA-2D dos conjuntos *Iris* e *Wine* padronizados, coloridos pelos rótulos de classe verdadeiros (não utilizados pelos algoritmos de agrupamento).

2 Questão 1 – BSAS combinado com agrupamento hierárquico

2.1 Ideia e formulação

O *Basic Sequential Algorithmic Scheme* (BSAS) atribui cada padrão ao agrupamento mais próximo se a dissimilaridade ao representante deste agrupamento for menor que um limiar τ ; caso contrário, cria um novo agrupamento, respeitando um número máximo q de agrupamentos permitidos. Essa formulação produz o número de agrupamentos $c(\tau)$ como uma função do parâmetro τ e da *ordem de apresentação* dos dados.

Para τ muito pequeno, quase todo padrão dispara a criação de um novo agrupamento e $c(\tau) \rightarrow m$. Para τ muito grande, todos os padrões caem em um único agrupamento e $c(\tau) = 1$. Entre os extremos, observa-se um **patamar** – intervalo no qual $c(\tau)$ permanece (aproximadamente) constante –, e o valor desse patamar é uma estimativa razoável do número intrínseco de agrupamentos.

Deteção do patamar via derivada discreta. Definimos uma malha $\tau_1 < \tau_2 < \dots < \tau_T$ no intervalo $[\tau_{\min}, \tau_{\max}]$, onde $\tau_{\min}$ e $\tau_{\max}$ são, respectivamente, a menor e a maior distância par-a-par dos dados. Como o BSAS depende da ordem dos padrões, repetimos R permutações aleatórias para cada τ_t e tomamos a **mediana** de $c(\tau_t)$. A derivada discreta

$$\Delta c_t = |c(\tau_{t+1}) - c(\tau_t)|, \quad t = 1, \dots, T-1, \quad (2)$$

sinaliza transições. Buscamos o **maior segmento contíguo com $\Delta c_t = 0$** (e $c(\tau) \geq 2$, descartando o patamar trivial $c = 1$); o valor de c neste segmento é o $\hat{k}$ estimado.

Particionamento. Com $\hat{k}$ em mãos, aplicamos o agrupamento aglomerativo de Ward, que minimiza o aumento de variância intra-cluster a cada fusão. Ward é menos sensível à ordem dos dados que o BSAS e produz partições mais coesas.

2.2 Algoritmo

Algorithm 1 BSAS clássico (com média incremental dos representantes)

Require: Conjunto $\mathcal{D} = \{x_i\}_{i=1}^m$, limiar τ , máximo q

```

1:  $c \leftarrow 0$ ,  $\mu_0 \leftarrow x_1$ ,  $\text{ind}(1) \leftarrow 0$ 
2: for  $i = 2, \dots, m$  do
3:    $k \leftarrow \arg \min_{j \in \{0, \dots, c\}} \|x_i - \mu_j\|$ 
4:   if  $\|x_i - \mu_k\| > \tau$  e  $c + 1 < q$  then
5:      $c \leftarrow c + 1$ ,  $\mu_c \leftarrow x_i$ ,  $\text{ind}(i) \leftarrow c$ 
6:   else
7:      $\mu_k \leftarrow \mu_k + (x_i - \mu_k) / (\#G_k + 1)$ 
8:      $\text{ind}(i) \leftarrow k$ 
9:   end if
10: end for
11: return ind

```

2.3 Resultados

A Figura 2 exibe a curva $c(\tau)$ obtida (mediana sobre 15 permutações) e a derivada discreta correspondente para os dois conjuntos. Em *Iris*, identifica-se um patamar dominante em $c = 2$ (separação de *setosa* contra o restante), resultando em $\hat{k} = 2$. Em *Wine*, o patamar mais longo com $c \geq 2$ ocorre em $c = 3$, coincidindo com o número real de classes.






Figura 2: Mediana de $c(\tau)$ (vermelho) e derivada discreta $|\Delta c / \Delta \tau|$ (azul). A linha tracejada indica o $\hat{k}$ estimado pelo patamar dominante.

A Figura 3 mostra os agrupamentos resultantes da pipeline BSAS→Ward sobrepostos à projeção PCA-2D.



(a) Iris.



(b) Wine.

Figura 3: Comparação entre rótulos verdadeiros (à esquerda) e o agrupamento BSAS→Ward com $\hat{k}$ estimado (à direita).

3 Questão 2a – Janelas de Parzen e *mode-seeking*

3.1 Ideia e formulação

A estimativa de Parzen com kernel gaussiano isotrópico é

$$\hat{p}(x) = \frac{1}{mh^n} \sum_{i=1}^m \varphi\left(\frac{x - x_i}{h}\right), \quad \varphi(z) = \frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{1}{2} z^\top z\right). \quad (3)$$

A largura h controla o trade-off viés-variância: h pequeno gera muitas modas espúrias; h grande coalesce modas reais.

Proposta criativa: *mode-seeking por mean-shift*. Em vez de varrer uma grade n -dimensional para localizar máximos de $\hat{p}$ (proibitivo para $n > 3$), partimos cada padrão x_i subindo na densi-

dade pelo gradiente local. O passo de *mean-shift* com kernel gaussiano é

$$x_i^{(t+1)} = \frac{\sum_{j=1}^m \varphi((x_i^{(t)} - x_j)/h) x_j}{\sum_{j=1}^m \varphi((x_i^{(t)} - x_j)/h)}, \quad (4)$$

iterado até convergência. Padrões cujas trajetórias terminam na mesma moda (dentro de uma tolerância $\varepsilon = h/2$) são atribuídos ao mesmo agrupamento. O número de agrupamentos é portanto **emergente**: nunca é informado.

Escolha de h . Como heurística inicial usamos a regra de Silverman:

$$h_0 = \bar{\sigma} \left(\frac{4}{(n+2)m} \right)^{1/(n+4)}, \quad \bar{\sigma} = \frac{1}{n} \sum_{j=1}^n \sigma_j, \quad (5)$$

e variamos $h = \alpha \cdot h_0$ com $\alpha \in \{0,6; 0,8; 1,0; 1,3; 1,6; 2,0\}$.

3.2 Resultados

A Figura 4 resume a sensibilidade do método à largura h em ambos os datasets. Em *Iris*, o número de agrupamentos cai de $K = 10$ (h pequeno) a $K = 2$ (h grande); o melhor ARI ocorre em $h \approx 0,66$, com $K = 2$. Em *Wine*, h pequeno produz quase tantos agrupamentos quanto pontos – consequência da **maldição da dimensionalidade**: em $n = 13$, kernels gaussianos isotrópicos perdem massa muito rapidamente. Apenas com h suficientemente grande surgem modas com massa apreciável.






Figura 4: Sensibilidade do número de agrupamentos K (vermelho) e do ARI (azul) à largura h em *Iris* e *Wine*.



(a) Iris.



(b) Wine.

Figura 5: À esquerda, superfícies de densidade de Parzen estimadas *na projeção PCA-2D* (apenas para visualização). À direita, agrupamentos obtidos pelo *mean-shift* aplicado ao espaço padronizado original.

4 Questão 2b – KNN com vizinhança mútua e densidade adaptativa

4.1 Ideia e formulação

A estimativa de densidade k -NN é *adaptativa*: fixamos o número de vizinhos k e medimos o volume da menor hipersfera centrada em x que contém esses k vizinhos:

$$\hat{p}(x) = \frac{k}{m V_k(x)}, \quad V_k(x) = V_0 \rho_k(x)^n, \quad (6)$$

onde $\rho_k(x)$ é a distância ao k -ésimo vizinho mais próximo de x .

Proposta criativa: mkNN com filtragem por densidade. Combinamos duas ferramentas em um único pipeline:


1. **Grafo de k -vizinhos mútuos (mkNN).** Há aresta entre x_i e x_j se e somente se cada um aparece na lista dos k vizinhos mais próximos do outro. A vizinhança mútua suprime “pontes” espúrias entre clusters distintos que um grafo k -NN dirigido criaria.
2. **Filtragem por densidade local.** Usando (6), classificamos como *ruído* todos os padrões com densidade abaixo do percentil $p_{\text{low}} = 10\%$; eles são removidos do grafo antes da extração de componentes conexos e reatribuídos *a posteriori* ao cluster do vizinho não-ruído mais próximo.

O número de clusters **emerge** dos componentes conexos do grafo restrito aos pontos de densidade suficiente.


Escolha de k . A heurística clássica $k \approx \sqrt{m}$ produz $k \approx 12$ para *Iris* e $k \approx 13$ para *Wine*. Variamos $k \in \{5, 7, 10, 15, 20, 30\}$ para estudar sensibilidade. Após a varredura, escolhemos o k que maximiza ARI – métrica que penaliza tanto fragmentação quanto fusão excessiva.

4.2 Resultados

A Figura 6 exibe a densidade k -NN estimada em PCA-2D e os agrupamentos finais. Em *Iris*, o melhor k foi 10, produzindo $K = 2$ componentes que correspondem essencialmente a *setosa* vs. *versicolor+virginica*. Em *Wine*, a melhor configuração foi $k = 5$ com $K = 4$ componentes; valores maiores de k saturam o grafo, fundindo todas as classes em um único componente conexo.



(a) Iris.



(b) Wine.

Figura 6: À esquerda, densidade k -NN estimada (cor); à direita, agrupamento por componentes conexos do grafo mkNN, com filtragem de pontos de baixa densidade.

5 Comparação geral

A Tabela 1 consolida as métricas qualitativas para os três métodos em ambos os datasets. Avaliamos: K (número de clusters preditos), acc^* (acurácia após alinhamento ótimo dos rótulos via algoritmo Hungarian), ARI (*Adjusted Rand Index*) e NMI (*Normalized Mutual Information*). Os índices ARI e NMI independem da permutação dos rótulos.

Tabela 1: Resumo qualitativo dos agrupamentos obtidos. acc^* usa alinhamento ótimo de rótulos.

Dataset	Método	K	acc^*	ARI	NMI
<i>Iris</i>	BSAS→Ward	2	0,660	0,544	0,692
	Parzen mode-seek	2	0,667	0,568	0,734
	KNN mkNN+densid.	2	0,667	0,568	0,734
<i>Wine</i>	BSAS→Ward	3	0,927	0,790	0,786
	Parzen mode-seek	12	0,899	0,781	0,752
	KNN mkNN+densid.	4	0,904	0,761	0,762

A Figura 7 apresenta as matrizes de confusão correspondentes (já alinhadas pelo Hungarian).




Figura 7: Matrizes de confusão (linhas: classe verdadeira; colunas: cluster predito após alinhamento) para os três métodos em *Iris* (acima) e *Wine* (abaixo).

6 Discussão crítica

6.1 BSAS combinado com Ward

A combinação se mostrou eficaz em *Wine*, no qual o patamar em $c = 3$ é claro e Ward, após padronização, recupera as três classes com 92,7% de acurácia. Em *Iris*, contudo, o patamar mais longo ocorre em $c = 2$: a separação entre *setosa* e o restante é tão evidente que domina a curva. Essa observação reflete uma limitação **semântica**: o número de agrupamentos “naturalmente” presente nos dados pode não coincidir com o número de classes de interesse para o problema. Heurísticas alternativas (e.g., usar o *segundo* patamar mais longo ou exigir $c \geq c_{\min}$) corrigem isso quando há informação prévia sobre K . A **sensibilidade à ordem** do BSAS foi mitigada com a mediana sobre 15 permutações, mas o método permanece menos robusto que abordagens hierárquicas para o particionamento final, motivando a escolha de Ward.

6.2 Parzen com *mode-seeking*

A grande vantagem é dispensar a especificação de K : ele emerge da topologia da densidade. A grande limitação é a **forte dependência de h** (Figura 4). Em *Wine* ($n = 13$), kernels gaussianos isotrópicos sofrem com a maldição da dimensionalidade: a regra de Silverman subestima a largura ideal e $h_0 = 0,68$ produz $K = 114$. Apenas em $\alpha \geq 1,3$ a estimativa começa a ter modas com massa apreciável, e o número de agrupamentos só atinge valores razoáveis em $\alpha = 2,0$. A acurácia final, no entanto, é alta após o alinhamento – evidência de que os 12 modos encontrados em $\alpha = 1,6$ são *sub-clusters* corretamente nidificados nas três classes. Custo computacional: $\mathcal{O}(T \cdot m^2 \cdot n)$ por iteração de *mean-shift*, viável para datasets pequenos como os deste trabalho.

6.3 KNN mkNN com densidade

A vantagem do KNN é a **adaptatividade**: a largura local muda conforme a densidade. O grafo mkNN reduz pontes entre clusters densos. Em *Iris*, o método encontra naturalmente $K = 2$, refletindo a estrutura bimodal real dos dados padronizados. Em *Wine*, é **altamente sensível a k** : $k = 5$ funciona bem, mas $k \geq 7$ satura o grafo e tudo vira um único componente. Esse comportamento é intrínseco a métodos baseados em conectividade: para datasets em que classes se tocam densamente (como *Wine* no espaço padronizado), uma única “ponte” robusta é suficiente para fundir clusters semânticos distintos. O filtro por percentil ajuda, mas adiciona um hiperparâmetro a ser ajustado. Aprimoramentos possíveis incluem: ponderação das arestas pela densidade local, uso de cortes mínimos no grafo, ou substituir componentes conexos por um critério de modularidade.

6.4 Considerações finais

Nenhum método domina simultaneamente os dois datasets, o que reforça o princípio de que a *escolha do algoritmo é parte do problema*. A combinação BSAS→Ward forneceu o melhor desempenho em *Wine*, em que classes ficam aproximadamente esféricas após padronização. As abordagens baseadas em densidade (Parzen e KNN) capturaram melhor a bimodalidade clara de *Iris*, ao custo de não recuperar as três classes semânticas. Em uma aplicação real, recomendamos o uso *combinado*: o BSAS oferece uma estimativa rápida de $\hat{K}$, enquanto Parzen e KNN servem como diagnóstico topológico (modas, regiões de baixa densidade, candidatos a outliers). Esses três pontos de vista, complementares, fornecem um retrato mais rico da estrutura dos dados que qualquer método isoladamente.